

PODSTAWY TEORII INFORMACJI

Laboratorium 3

Raport projektowy MiniInfo

MiniInfo - Raport 3: Ekstrakcja informacji

Autorzy

Goran Pangelow
Marcin Pawlak
Mikołaj Pesta
Ignacy Drężek
Iga Oleksiewicz
Maks Młynarczyk

10 maja 2026

Spis treści

1	Sprostowanie i poprawa Raportu 2	2
1.1	Ekstrapolacja i zbieranie danych	2
1.2	Mikrofony i badanie dźwięku	3
1.3	Częstotliwość próbkowania a dynamika procesu	4
2	Wstęp do etapu trzeciego: Potok ekstrakcji informacji	5
3	Symulacja zakłóceń i filtracja sygnałów z czujników mmWave (Przetwarzanie celem ekstrakcji)	6
3.1	Charakterystyka szumu w detekcji radiowej na Wydziale MiNI	6
3.2	Symulacja zniekształceń sygnału wejściowego	6
3.3	Metody redukcji i filtry wygładzające	6
4	Segmentacja przestrzeni i ekstrakcja obiektów zainteresowania (Aproksymacja treści)	6
4.1	Założenia segmentacji obszarowej w sali	6
4.2	Algorytm ekstrakcji sylwetek	7
4.3	Interpretacja sceny na potrzeby użytkownika	7
5	Selektywny przesył i kompresja informacji (Kompresja z selekcją)	8
5.1	Uwarunkowania przesyłu i redundancja stanów	8
5.2	Metody kompresji bezstratnej sygnałów dyskretnych	8
5.3	Eksperymentalna ocena wydajności (Rate-Distortion) . . .	9
6	Podsumowanie i wnioski z etapu trzeciego	9

1 Sprostowanie i poprawa Raportu 2

Po ocenie Raportu 2 od Profesora uzupełniamy i doprecyzowujemy wcześniejsze założenia systemu MiniInfo. Poniższe podsekcje odnoszą się do trzech obszarów, które wymagały korekty przed przejściem do opisu potoku ekstrakcji informacji w Etapie 3: prognozowanie obłożenia (a nie wyłącznie stan bieżący), uwzględnienie natężenia dźwięku obok zajętości stref oraz świadome rozdzielenie częstotliwości próbkowania technicznego od agregacji danych prezentowanych użytkownikowi.

1.1 Ekstrapolacja i zbieranie danych

W odpowiedzi na uwagi do Raportu 2 doprecyzowujemy wcześniejszy opis i opisujemy zmiany wprowadzone w systemie. W Raporcie 2 opisaliśmy głównie warstwę semantyczną i pragmatyczną dla *aktualnego* stanu sal (progi obłożenia, kolory kafelków, rekomendacje alternatywnych stref), bez wyraźnej ścieżki od szeregu historycznego do prognozy. Po konsultacjach rozszerzyliśmy zakres projektu: użytkownik ma nie tylko widzieć, czy pokój JetBrains lub salka Nauki jest teraz wolny, ale także orientować się, jak zajętość może wyglądać w najbliższej przyszłości, np. za godzinę lub w typowy wtorek po południu.

Do tego celu wykorzystujemy dane zgromadzone w poprzednich tygodniach pracy systemu. Analizę uruchamiamy cyklicznie — w praktyce co tydzień, po zebraniu wystarczającej liczby próbek z wszystkich monitorowanych stref. Na wejściu mamy szereg czasowy zajętości (ułamek miejsc zajętych lub liczba osób względem pojemności sali); na wyjściu krótkoterminową prognozę oraz wygładzoną tendencję. Stosujemy dwie proste metody statystyczne, które dobrze sprawdzają się przy regularnym rytmie dnia uczeniowego: średnią ruchomą (do szybkiego wygładzenia szumu i wychwycenia lokalnego trendu) oraz wygładzanie wykładnicze Holt–Wintersa z sezonowością tygodniową (do oddania powtarzalności dni roboczych i różnic między poniedziałkiem a piątkiem).

Model nie jest rozbudowanym modułem uczenia maszynowego — świadomie pozostaliśmy przy metodach interpretowalnych, żeby w raporcie i w kodzie dało się wytłumaczyć każdą decyzję. W typowych tygodniach semestru prognoza zapełnienia sal jest użyteczna: student widzi, czy warto iść od razu do wybranej strefy, czy lepiej poczekać lub wybrać sąsiednią salę. Problem pojawia się przy nagłych odchyleniach od rutyny. Najczęściej obserwowaliśmy to podczas wydarzeń organizowanych na Politechnice Warszawskiej (konferencje, dni otwarte, zjazdy organizacji studenckich), gdy ruch w budynku nie przypomina zwykłego rozkładu zajęć. Wtedy histo-

ryczne wzorce wprowadzają w błąd i prognoza wyraźnie odbiega od rzeczywistości — czasem bardziej niż sam odczyt bieżący po agregacji opisanej w podsekcji 1.3.

Nad tym pracowaliśmy przez ostatnie tygodnie implementacji: testowaliśmy długość okna średniej ruchomej, parametry sezonowości w Holt–Wintersie oraz to, jak prognozę mapować na te same progi pragmatyczne co w Raporcie 2 (Wolne, Umiarkowany ruch, Prawie pełny itd.), żeby interfejs w lobby pozostał spójny. Szczegóły obsługi anomalii i zdarzeń specjalnych omawiamy dalej w raporcie; tutaj zaznaczamy jedynie, że warstwa predykcji jest już częścią projektu, a nie zapowiedzią na przyszłość.

1.2 Mikrofony i badanie dźwięku

Zgodnie z sugestią Profesora, obok mierzenia zapełnienia stref rozważyliśmy także problem głośności i szumu w badanych miejscach. W Raporcie 2 skupialiśmy się na torze mmWave i liczbie osób; nie opisaliśmy tam kanału akustycznego, choć nasze czujniki udostępniają pomiar natężenia dźwięku. Uzupełnienie tego toru było naturalnym krokiem: sama zajętość nie mówi, czy sala przy pełnym obłożeniu nadal nadaje się do cichej pracy, czy jest hałaśliwa jak korytarz między wykładami.

Pomiar dźwięku ma inną charakterystykę niż detekcja obecności radiowej. Wartości potrafią skoczyć w ułamku sekundy (trzask drzwi, rozmowa przechodząca obok, krótki śmiech w grupie). Gdybyśmy pokazywali surowy poziom na ekranie w lobby, wykres i kafelki „migąłyby” bez związku z ogólnym komfortem pracy w strefie. Zastosowaliśmy więc dość rygorystyczne uśrednianie — analogiczne w duchu do agregacji czasowej zajętości z podsekcji 1.3: zbieramy próbki często, ale do oceny strefy i do zestawienia z zajętością przekazujemy wartości uśrednione w dłuższym oknie. Dzięki temu chwilowe hałasy nie zaburzają ogólnego obrazu miejsca.

Informacje o natężeniu dźwięku zestawiliśmy bezpośrednio z danymi o zajętości sal. W praktyce dla każdej strefy i przedziału czasu mamy parę: szacowana liczba osób (lub procent obłożenia) oraz reprezentatywny poziom hałasu. Pozwala to opisać charakter miejsca precyzyjniej niż samym kolorem kafelka. Przykłady z testów na Wydziale MiNI: salka Nauki przy umiarkowanym obłożeniu często pozostaje cicha; pokój JetBrains przy wysokim obłożeniu bywa głośny z powodu pracy grupowej, mimo że liczba wykrytych osób jest podobna. Takie zestawienie zwiększa wartość użytkową informacji dla studenta szukającego miejsca do nauki i jest spójne z warstwą pragmatyczną z Raportu 2 — komunikat może sugerować nie tylko „jest wolne”, ale „jest wolno i cicho”.

Na monitorach w lobby nie planujemy osobnego wykresu decybeli; po-

ziom hałasu wchodzi do logiki opisu strefy i ewentualnych rekomendacji (np. przekierowanie do cichszej sali przy podobnej zajętości). Implementacyjnie kanał akustyczny korzysta z tej samej infrastruktury transmisji co odczyty z radaru (sieć czujników, zbieranie na serwerze), co ułatwia synchronizację znaczników czasu z toru mmWave i toru dźwiękowego.

1.3 Częstotliwość próbkowania a dynamika procesu

Kolejną istotną uwagą było nasze zbytne skupienie na śledzeniu zachowań w czasie rzeczywistym oraz nieprecyzyjne posługiwanie się pojęciem aliasingu. W Raporcie 2 odwoływaliśmy się do twierdzenia Nyquista–Shannona i aliasingu przy doborze interwału próbkowania T_s (przyjeliśmy tam m.in. $T_s = 60$ s jako kompromis między aktualnością a kosztem transmisji w ZigBee). Jednocześnie przy wyjaśnianiu krótkich skoków liczby wykrytych osób czasem używaliśmy słowa „aliasing” w szerszym, potocznym sensie. Po dalszych testach w salach uznaliśmy, że w typowych warunkach na Wydziale dominuje raczej dynamika sceny — ludzie wychodzą na chwilę, przemieszczają się między stanowiskami, zasłaniają sobie pole widzenia radaru — niż klasyczny błąd podpróbkowania sygnału w rozumieniu teorii sygnałów. To ważne rozróżnienie: poprawiamy terminologię w raporcie, nie zmieniając przy tym faktu, że $T_s = 60$ s nadal uznajemy za rozsądny do zbierania surowych danych.

Problem praktyczny wyglądał tak: pojedyncza próbka co minutę mogła na chwilę zaniżyć lub zawyżyć liczbę osób, a algorytm semantyczny z Raportu 2 od razu mapował taki odczyt na jeden z pięciu stanów interfejsu (zielony, żółty, prawie pełny itd.). Efektem były niepotrzebne zmiany koloru kafelka i szum w szeregu, z którego dopiero mieliśmy budować prognozy (podsekcja 1.1). Student w holu nie potrzebuje informacji, że w sekundzie t radar „zagubił” jedną osobę za plecami kolegi; potrzebuje stabilnej odpowiedzi: czy w *tym* półgodzinnym bloku sala była raczej wolna, czy raczej pełna.

Dlatego rozdzieliliśmy warstwę pomiaru od warstwy informacji dla użytkownika. Surowe odczyty z czujników mmWave nadal zapisujemy z częstotliwością wynikającą z T_s i potrzeb analizy (filtracja, archiwum, kalibracja). Natomiast stan strefy na ekranach oraz wejście do modelu prognozowania wyliczamy jako średnią zajętość w oknach **półgodzinnych** i **godzinnych**, po wstępnym odrzuceniu oczywistych artefaktów (krótkie skoki niewspółmierne do pojemności sali, pojedyncze próbki odstające od sąsiadów). W każdym oknie liczymy reprezentatywną wartość zajętości, a dopiero z niej wyznaczamy progi pragmatyczne znane z Raportu 2. Pojedyncze „miganie” detekcji nie przełącza od razu koloru kafelka.

Takie podejście lepiej oddaje dynamikę całego procesu w salach nauki. Średni czas przebywania studenta w jednej strefie to zwykle wiele minut, a nie sekundy; rotacja miejsc ma sens w skali dziesiątek minut. Agregacja półgodzinowa i godzinna jest zatem bliższa temu, co użytkownik końcowy rozumie jako „teraz w tej sali jest tłoczno”, bez rezygnacji z dokładniejszego zapisu surowego po stronie serwera. Uprościło to model prognoz, ograniczyło fałszywe alarmy przy rekomendacji alternatywnych sal i dało spójniejszy sygnał wejściowy do filtrów opisanych w rozdziale o przetwarzaniu sygnałów z czujników mmWave — tam wracamy do szczegółów usuwania szpilek, szumu tła i symulacji zakłóceń na przygotowanych szeregach.

2 Wstęp do etapu trzeciego: Potok ekstrakcji informacji

W Raporcie 2 zdefiniowaliśmy syntaktyczne oraz semantyczne ramy systemu „MINI Info”, którego zadaniem jest dostarczanie pragmatycznej wiedzy o zajętości stref nauki (np. pokoju JetBrains) na ekrany w lobby. Potwierdziliśmy skuteczność wykorzystania czujników fal milimetrowych (mmWave) ze względu na ochronę prywatności (brak danych RODO) w porównaniu do kamer CCTV. Obliczyliśmy także entropię układu oraz zaprojektowaliśmy system transmisji oparty o MQTT.

Niniejszy raport (Etap 3) stanowi bezpośrednią kontynuację naszych prac i skupia się na procesie zdefiniowanym jako **Ekstrakcja informacji**. O ile Raport 2 określał, *dlaczego* zbieramy takie a nie inne sygnały, o tyle Raport 3 analizuje wnikliwie, *w jaki sposób* nasz system technicznie wydobywa wartość z chaosu surowych odczytów radiowych. Aby zrealizować to zadanie rzetelnie i zminimalizować interferencje między poszczególnymi metodami obliczeniowymi, zaprojektowaliśmy ścisły potok przetwarzania danych (ang. *data pipeline*).

Rozdziały w tym raporcie to w rzeczywistości kolejne węzły tego potoku: począwszy od sprzętowej filtracji szumów wejściowych radaru, przez przestrzenną ekstrakcję sylwetek studentów, aż po bezstratną kompresję ostatecznej wiedzy z użyciem algorytmów strumieniowych.

3 Symulacja zakłóceń i filtracja sygnałów z czujników mmWave (Przetwarzanie celem ekstrakcji)

3.1 Charakterystyka szumu w detekcji radiowej na Wydziale MiNI

W środowisku rzeczywistym, takim jak sale nauki na Wydziale, sprzęt zbierający dane nigdy nie dostarcza sygnału idealnego. Radary mmWave działają w oparciu o efekt Dopplera i mapowanie chmury punktów (point cloud), co czyni je wrażliwymi na... [DO UZUPEŁNIENIA].

3.2 Symulacja zniekształceń sygnału wejściowego

Na potrzeby eksperymentalne zdefiniowaliśmy bazowy strumień danych dla sali JetBrains reprezentujący 10 osób siedzących w bezruchu przez 60 minut. Następnie na sygnał nałożono losowy szum gaussowski oraz symulowane szpilki błędów (artefakty), imitujące... [DO UZUPEŁNIENIA: wzory lub opis, wykres zaszumionego sygnału].

3.3 Metody redukcji i filtry wygładzające

W celu estymacji zakłóceń zastosowano filtrację. Odrzucono krótkotrwałe skoki odczytów powyżej 500% różnicy (artefakty). Dla łagodnego szumu tła zaimplementowano... [DO UZUPEŁNIENIA]. Uzyskany w ten sposób oczyszczony ciąg syntaktyczny przekazywany jest do kolejnej warstwy analitycznej.

4 Segmentacja przestrzeni i ekstrakcja obiektów zainteresowania (Aproksymacja treści)

4.1 Założenia segmentacji obszarowej w sali


W systemie opartym na radarach fal milimetrowych (mmWave), sygnał oznaczający obecność osób nie jest standardowym obrazem wideo. Czujnik zwraca jedynie przestrzenną chmurę punktów (odbitych mikrofal). Aby wydobyć z niej użyteczną informację, dzielimy fizyczną przestrzeń pokoju

(np. Strefę JetBrains) na zdefiniowane wcześniej regiony zainteresowania (ang. *Regions of Interest* – ROI).

Dzięki temu nie musimy śledzić każdego ruchu w całej sali. System skupia się tylko na tych strefach, które definiują "zajęte miejsce" (krzesła, biurka, kanapy), a ignoruje ciągi komunikacyjne (np. środek pokoju czy korytarz wejściowy). Takie podejście pozwala już na najniższym poziomie odrzucić niepotrzebne tło i skupić się na właściwej informacji.

4.2 Algorytm ekstrakcji sylwetek

Mając przygotowaną mapę ROI, urządzenie przechodzi do właściwej ekstrakcji danych. Zamiast skomplikowanego rozpoznawania obrazu, system po prostu grupuje przestrzenne odbicia radarowe, które zachowują się jak ludzka sylwetka (wykrywa m.in. rytmiczne mikro-ruchy klatki piersiowej przy oddychaniu, co pozwala odróżnić żywego człowieka od pracującego wentylatora).



Rysunek 1: Wizualizacja ekstrakcji sylwetek: grupowanie zagęszczonych odbić radarowych na tle rzadkiego szumu otoczenia.

Z punktu widzenia Teorii Informacji jest to proces silnej selekcji danych. Sensor mmWave odfiltrowuje szum oraz tzw. efekt pustego przelotu (np. rzucony plecak lub osobę tylko przechodzącą przez salę). Na wyjściu otrzymujemy po prostu dyskretną wartość liczbową, która mówi nam, ile sylwetek znajduje się aktualnie w oznaczonych strefach ROI.

4.3 Interpretacja sceny na potrzeby użytkownika

Sama wyekstrahowana liczba osób (np. 15 stabilnych detekcji w ROI) to jeszcze nie jest końcowa wiedza dla użytkownika. Trzeba ją zinterpretować

pod kątem potrzeb studentów na Wydziale MiNI. System nie analizuje dokładnych pozycji ludzi (byłoby to nadmiarowe i naruszało prywatność), lecz skupia się na stopniu zapełnienia sali.

Interpretacja polega na odniesieniu liczby wykrytych sylwetek do maksymalnej pojemności danego pomieszczenia. Zajętość względna O wyraża się wzorem:

$$O = \frac{N_{\text{detekcji}}}{C_{\text{max}}} \cdot 100\% \quad (1)$$

gdzie N_{detekcji} to liczba osób zmierzona przez radar, a C_{max} to pojemność udostępnionych stref ROI. To zestawienie pozwala systemowi wygenerować ostateczny komunikat dla studenta, mapując procenty za pomocą prostej funkcji progowej:

$$\text{Status} = \begin{cases} \text{Wolne,} & \text{dla } O < 30\% \\ \text{Umiarkowany ruch,} & \text{dla } 30\% \leq O < 75\% \\ \text{Prawie pełny,} & \text{dla } O \geq 75\% \end{cases} \quad (2)$$

W ten sposób mocno rozproszone dane z czujników mikrofalowych są kompresowane do pojedynczego, użytecznego komunikatu pragmatycznego, który można wyświetlić na monitorach w holu.

5 Selektywny przesył i kompresja informacji (Kompresja z selekcją)

5.1 Uwarunkowania przesyłu i redundancja stanów

Wyekstrahowana wiedza o zajętości musi ostatecznie trafić na główny serwer MQTT połączony z wyświetlaczami w budynku. Jak wykazano w Raporcie 2, przy statycznych godzinach nauki, stany (np. Zielony, Żółty) mogą utrzymywać się przez dziesiątki minut, co generuje ogromną nadmiarowość. W tym kroku następuje organizacja indeksu i optymalizacja struktury danych [DO UZUPEŁNIENIA].

5.2 Metody kompresji bezstratnej sygnałów dyskretnych

Dla celów archiwizacji logów dobowych z całego wydziału (istotne dla analiz długoterminowych) system kompresuje wynikowe raporty z użyciem kodu... [DO UZUPEŁNIENIA: wybór i krótki opis kodu, np. algorytm Huffmana dopasowany do prawdopodobieństw stanów wyliczonych w raporcie 2].

5.3 Eksperymentalna ocena wydajności (Rate-Distortion)

Ostateczna efektywność potoku została zweryfikowana empirycznie. Dzięki zastosowaniu selektywnego informowania tylko o zmianach krytycznych oraz dzięki wysokiej kompresji plików archiwizacyjnych, dobowy rozmiar wygenerowanych danych dla całego budynku zmniejszono o... [DO UZUPEŁNIENIA].

6 Podsumowanie i wnioski z etapu trzeciego

W toku realizacji laboratoriów trzecich udowodniono, że użyteczna wartość pragmatyczna (kolorowy kafelek na ekranie monitora) nie jest procesem bezpośrednim, a wymaga wdrożenia wieloetapowego filtru analitycznego. Podział zagadnień ekstrakcji danych na trzy wyspecjalizowane kroki (filtracja falowa, segmentacja i aproksymacja treści, optymalna pod kątem entropii sieć dystrybucyjna) tworzy potok przetwarzania pozwalający uzyskać czystą wiedzę decyzyjną, oferując jednocześnie znacząco niższe obciążenie sieciowe niż systemy wideo, z którymi MiniInfo konkurencyjnie się zestawia.

Podział prac

- Rozdział 1 – Goran Pangelow
- Rozdział 2 – Marcin Pawlak
- Rozdział 3 – Mikołaj Pesta
- Rozdział 4 – Ignacy Drężek
- Rozdział 5 – Maks Młynarczyk
- Rozdział 6 – Iga Oleksiewicz
- Redakcja raportu – Marcin Pawlak