



**Wydział Matematyki
i Nauk Informatycznych**

POLITECHNIKA WARSZAWSKA

PODSTAWY TEORII INFORMACJI

Laboratorium 4

Raport projektowy MiniInfo

MiniInfo - Raport 4: Semantyka i Wyszukiwanie Informacji

Autorzy

Goran Pangelow

Marcin Pawlak

Mikołaj Pesta

Ignacy Drężek

Iga Oleksiewicz

Maks Młynarczyk

26 maja 2026

Spis treści

1	Odpowiedź na uwagi do Raportu 3 i kierunek Etapu 4	2
1.1	Predykcja obłożenia w szerszej perspektywie czasowej . . .	2
1.2	Model zachowań, dynamika sali i ograniczenia pomiaru . .	2
1.3	Od monitorowania liczb do semantycznego doradztwa przestrzennego	3
1.4	Konkretne mechanizmy zamiast kolejnej warstwy filozofii .	4
2	Profilowanie użytkownika: Ankieta oczekiwań (Modele Od- biorcy)	4
2.1	Koncepcja ankiety w interfejsie aplikacji	5
2.2	Mapowanie odpowiedzi na parametry numeryczne systemu	6
2.3	Definicje predefiniowanych modeli (profilu) użytkownika . .	7
2.4	Subiektywna skala semantyczna oraz kalibracja z udziałem testerów	8
2.5	Przeprowadzenie ankiety i zbieranie danych	9
3	Dane i mechanizmy działania aplikacji	9
3.1	Jak przechowujemy informacje o salach?	9
3.2	Pobieranie danych z czujników w czasie rzeczywistym . . .	10
3.3	Reakcja na zgłoszenia studentów (Algorytm Rocchio) . . .	10
4	Procedury odpytywania i mechanizmy wyszukiwania	11
4.1	Konstrukcja zapytania na podstawie profilu	11
4.2	Ważona odległość Euklidesowa jako miara dopasowania . .	12
4.3	Przyjazna interpretacja i prezentacja wyników	12
4.4	Kryteria oceny i selektywność wyszukiwania	13
5	Pierwsze testy działającej aplikacji ze studentami	14
5.1	Cel i założenia badawcze	14
5.2	Protokół eksperymentu terenowego	14
5.3	Uczestnicy i charakterystyka próby	15
5.4	Wyniki ankiety profilującej i wyboru sal	16
5.5	Feedback po wizycie: zadowolenie i zgodność z oczekiwaniami	17
5.6	Zbieranie błędów i rozbieżności między sensorem a percepcją	18
5.7	Powiązanie z oceną skuteczności wyszukiwania (Rozdział 4)	18
5.8	Wnioski wstępne i ograniczenia badania	18
6	Podsumowanie etapu 4	19

1 Odpowiedź na uwagi do Raportu 3 i kierunek Etapu 4

Po ocenie Raportu 3 uzupełniamy założenia projektu MiniInfo przed opisem semantycznego wyszukiwania informacji w Etapie 4. Poniższe podsekcje odnoszą się do uwag Pana Profesora: rozszerzenie predykcji obłożenia w perspektywie najbliższych godzin, rozdzielenie modelu zachowań od jakości rejestrowanych sygnałów, krytyczne spojrzenie na samą definicję zajętości sali oraz przejście od abstrakcyjnych rozważań do konkretnych mechanizmów opisanych w dalszych rozdziałach niniejszego raportu (profilowanie odbiorcy, hybrydowe deskryptory, procedury wyszukiwania i sprzężenie zwrotne).

1.1 Predykcja obłożenia w szerszej perspektywie czasowej

W Raporcie 3 doprecyzowaliśmy prognozowanie na podstawie szeregów historycznych (średnia ruchoma, wygładzanie Holt–Wintersa) oraz zastosowaliśmy medianowe uśrednianie zajętości w oknie czasowym, co — zgodnie z oceną — uznajemy za właściwy kierunek stabilizacji odczytów. Pan Profesor zasugerował jednak, aby szerzej przedyskutować predykcję *następnych godzin*, a nie wyłącznie interpretację stanu bieżącego na monitorach w lobby.

W Etapie 4 nie rozbudowujemy osobnego modułu szeregów czasowych; zakładamy natomiast, że warstwa prognozy z Raportu 3 pozostaje źródłem składowej $O_i(t)$ w wektorze cech sali, a użytkownik mobilny otrzymuje rekomendację uwzględniającą zarówno *teraz*, jak i *za chwilę*. Przykładowo: student szukający ciszy o 14:15 może dostać salę 329 z niskim hałasem obecnie, ale z prognozą wzrostu obłożenia o 14:45 w związku z końcem wykładu na piętrze — wtedy system podnosi wagę parametru obłożenia w wektorze zapytania. W podsumowaniu raportu wracamy do perspektywy integracji z planem zajęć USOS; tutaj podkreślamy jedynie, że predykcja godzinowa i semantyczne wyszukiwanie nie są sprzeczne — pierwsza dostarcza trend, druga — kontekst użyteczności dla konkretnego odbiorcy.

1.2 Model zachowań, dynamika sali i ograniczenia pomiaru

Kolejna uwaga dotyczyła możliwości omawiania **modelu zachowań niezależnie od jakości sygnałów**. W poprzednich raportach mieszałyśmy

ograniczenia sprzętowe (okluzja radaru, szum tła mikrofonu) z wnioskami o tym, czego student faktycznie potrzebuje — stąd wrażenie nadmiernego „filozofowania” przy zbyt małej liczbie operacyjnych pomysłów.

W niniejszym etapie rozdzielamy te warstwy świadomości. **Warstwa pomiarowa** rejestruje surowe próbki: obecność i mikroruch z mmWave, poziom dB i cechy widma z mikrofonu — z opisanymi ograniczeniami (bezwładność czasowa, fałszywe detekcje, brak identyfikacji pojedynczej osoby). **Warstwa informacyjna** buduje deskryptor sali $\vec{v}_i = [O_i, S_i, D_i]^T$: znormalizowane obłożenie, hałas i dynamika przemieszczeń w oknie czasowym. Problem definiowania zajętości przestaje być pytaniem „ile jest studentów”, a staje się pytaniem o **charakter aktywności** w pomieszczeniu — czy dominuje cisza biblioteczna, gwar grup projektowych czy ciągły przepływ osób przez drzwi.

Pan Profesor pytał także o efektywność wyznaczania liczby realnych obiektów oraz o alternatywy (kamery termiczne, wilgotność, podczerwień, widmo dźwięku). Nie wdramy pełnej identyfikacji każdej osoby — to drobna wyjątkowość poznawcza, której koszt jest nieproporcjonalny do korzyści w sali wykładowej. Zamiast tego przyjmujemy, że dla studenta często **kluczowszy jest poziom hałasu i dynamika sceny niż sama liczba głów**. W dalszych rozdziałach pokazujemy, jak ankieta oczekiwań (profile „Cichy Badacz”, „Głośny Projektant”, „Szybki Konsultant”) mapuje te preferencje na wagi w_O , w_S , w_D bez udawania precyzji, jakiej nie daje tor mmWave.

1.3 Od monitorowania liczb do semantycznego doradztwa przestrzennego

Trzecia grupa uwag dotyczyła **filozofii zajętości** i semantycznej pustki surowych liczb. Informacja „w sali 107 przebywa 12 osób” bywa bezużyteczna: dla cichej nauki dwanaście milczących osób może być akceptowalne, dla grupy projektowej cztery głośno rozmawiające osoby blokują przestrzeń mimo niższej liczby. Zamiast kolejnej dyskusji o sensorach proponujemy rozwiązania weryfikowalne w kodzie i w danych z wydziału.

Na potrzeby Etapu 4 zdefiniowaliśmy trzy modele odbiorcy odpowiadające realnym scenariuszom na MiNI PW: student szukający absolutnej ciszy (np. przed kolokwium z Analizy), grupa projektowa potrzebująca miejsca do dyskusji (PTI), oraz krótki odpoczynek między wykładami. Każdy scenariusz ma inny wektor zapytania $\vec{q}$ i inne wagi w_O , w_S , w_D w **jednej** metryce rankingu — ważonej odległości Euklidesowej (Rozdziały 2–4). Zrezygnowaliśmy z podobieństwa kosinusowego: przy składowych z $[0, 1]$ wektory o różnej *treści*, ale tej samej *proporcji* (np. $\vec{q} = [0.1, 0.1, 0.1]^T$ i

$\vec{v} = [0.9, 0.9, 0.9]^T$) leżą na jednej półprostej i mogą otrzymać $\cos \theta = 1$, mimo że semantycznie oznaczają przeciwne warunki (cisza kontra tłok i gwar). Opieramy się wyłącznie na **rzeczywistych pomiarach** z sal 107, 329 i salki w bibliotece — bez danych syntetycznych — oraz wprost opisujemy ograniczenia technologii, bo — jak podkreślił Pan Profesor — systemów idealnych nie ma.

1.4 Konkretny mechanizmy zamiast kolejnej warstwy filozofii

Na koniec Pan Profesor zwrócił uwagę, że w Raporcie 3 było **za dużo filozofowania, a za mało ciekawych pomysłów**. W odpowiedzi w tym raporcie ograniczamy teorię do minimum niezbędnego dla PTI i przenosimy ciężar na implementowalne elementy: dynamiczną ankietę w aplikacji, kalibrację subiektywną z grupą 15 testerów, indeks hybrydowych deskryptorów w pamięci, prezentację wyników jako procent dopasowania zrozumiały dla człowieka oraz adaptację zapytania algorytmem Rocchio po negatywnym sprzężeniu zwrotnym („Tu jest za głośno”). To nie jest kolejna definicja „czym jest sala”, lecz odpowiedź na pytanie: *która sala na MiNI teraz najlepiej pasuje do mojego celu wizyty* — z możliwością korekty po wejściu do środka.

W kolejnych rozdziałach rozwijamy powyższe założenia: profilowanie użytkownika i wyniki ankiety (Rozdział 2), konstrukcję wektora $\vec{v}_i$ i indeksu (Rozdział 3), procedury wyszukiwania (Rozdział 4), pierwsze testy działającej aplikacji ze studentami (Rozdział 5) oraz podsumowanie etapu z perspektywą USOS (Rozdział 6).

2 Profilowanie użytkownika: Ankieta oczekiwań (Modele Odbiorcy)


W tradycyjnych systemach informacji przestrzennej (takich jak systemy monitoringu zajętości sal) użytkownik jest konfrontowany jedynie z surowymi wskaźnikami liczbowymi. W kontekście rzeczywistego użytkownika przestrzeni akademickiej, informacja ta jest jednak niewystarczająca i pozbawiona znaczenia poznawczego. Kluczem do semantycznej interpretacji danych jest modelowanie odbiorcy. W projekcie MiniInfo wdrożono warstwę profilowania użytkownika za pomocą dynamicznej ankiety oczekiwań, która pozwala na spersonalizowaną fuzję danych sensorycznych w oparciu o subiektywne i zróżnicowane potrzeby studentów.

2.1 Koncepcja ankiety w interfejsie aplikacji

Przed przystąpieniem do wyszukania optymalnego miejsca do nauki lub pracy, użytkownik uruchamia w aplikacji przeglądarkowej MiniInfo krótką, interaktywną ankietę składającą się z trzech pytań. Ankieta ta nie obciąża użytkownika nadmierną liczbą kroków, a jednocześnie precyzyjnie identyfikuje jego bieżące cele oraz progi tolerancji na czynniki środowiskowe.



Rysunek 1: Główny interfejs – ankieta profilująca



Rysunek 2: Wyniki wyszukiwania i profilowania

Studenci mają do wyboru następujące opcje:

1. Pytanie 1: Jaki jest główny cel Twojej wizyty w sali?

- [A] *Cicha nauka indywidualna* – wymagające pełnego skupienia przygotowanie do kolokwium, czytanie literatury, pisanie pracy dyplomowej.
- [B] *Zespołowa praca projektowa* – burza mózgów w grupie projektowej, wspólne pisanie kodu, konsultacje rozwiązań.
- [C] *Odpoczynek i oczekiwanie* – spędzenie czasu między wykładami, zjedzenie posiłku, szybkie przejrzanie planu zajęć.

2. Pytanie 2: Jaka jest Twoja wrażliwość na hałas panujący w otoczeniu?

- [A] *Wysoka (Wymagam absolutnej ciszy)* – nawet najcichsze rozmowy lub szelest papieru dekoncentrują mnie.
- [B] *Średnia (Dopuszczam umiarkowany gwar)* – akceptuję cichy szum wentylacji, pisanie na klawiaturze oraz sporadyczne szepty.
- [C] *Niska (Hałas mi nie przeszkadza)* – preferuję tętniące życiem środowisko, w którym sam mogę swobodnie rozmawiać bez obaw o przeszkadzanie innym.

3. Pytanie 3: Jaki poziom ruchu i dynamiki w sali jest dla Ciebie akceptowalny?

- [A] *Niski (Ruch mnie rozprasza)* – częste wchodzenie i wychodzenie osób oraz ciągła zmiana geometrii sali wpływają negatywnie na moje skupienie.
- [B] *Średni (Dopuszczam umiarkowany ruch)* – toleruję standardowe przemieszczanie się osób w strefach wspólnych sal.
- [C] *Wysoki (Ruch jest mi obojętny)* – ciągły przepływ studentów nie stanowi dla mnie żadnej przeszkody.

2.2 Mapowanie odpowiedzi na parametry numeryczne systemu

Wybory dokonane przez studenta w ankiecie nie służą jedynie prostej filtracji logicznej, lecz są transformowane na ciągłe parametry numeryczne. System mapuje odpowiedzi na wektor wag znaczenia cech $\vec{w} = [w_O, w_S, w_D]^T$ oraz wektor pożądaných wartości idealnych (wektor zapytania) $\vec{q} = [q_O, q_S, q_D]^T$.

Wartości te mieszczą się w znormalizowanym przedziale $[0, 1]$. Szczegółowy schemat mapowania przedstawiono w Tabeli 1.

Tabela 1: Schemat mapowania odpowiedzi z ankiety na wagi cech i wektor zapytania.

Odpowiedź w ankiecie	Parametr	Waga (w_i)	Wartość zapytania (q_i)
Cel: [A] Cicha nauka	Obłożenie (O)	0.8	0.1
Cel: [B] Praca projektowa	Obłożenie (O)	0.3	0.5
Cel: [C] Odpoczynek	Obłożenie (O)	0.5	0.4
Hałas: [A] Wysoka wrażliwość	Szum (S)	1.0	0.0
Hałas: [B] Średnia wrażliwość	Szum (S)	0.6	0.3
Hałas: [C] Niska wrażliwość	Szum (S)	0.8	0.7
Ruch: [A] Niski akceptowalny	Dynamika (D)	0.7	0.1
Ruch: [B] Średni akceptowalny	Dynamika (D)	0.4	0.4
Ruch: [C] Wysoki akceptowalny	Dynamika (D)	0.1	0.8

2.3 Definicje predefiniowanych modeli (profilu) użytkownika

Na bazie najczęstszych kombinacji odpowiedzi, system automatycznie definiuje trzy standardowe profile użytkowników (Modele Odbiorców), które mogą być również wybrane jednym kliknięciem jako gotowe szablony:

- **Model I: „Cicha nauka”**

Dedykowany do cichej pracy indywidualnej. System dąży do zminimalizowania wszelkich zakłóceń. Wagi i wartości docelowe:

$$\vec{w}_{\text{badacz}} = \begin{bmatrix} 0.8 \\ 1.0 \\ 0.7 \end{bmatrix}, \quad \vec{q}_{\text{badacz}} = \begin{bmatrix} 0.1 \\ 0.0 \\ 0.1 \end{bmatrix} \quad (1)$$

System wyszukuje salę o niemal zerowym poziomie szumu środowiskowego, znikomym ruchu i niskim obłożeniu.

- **Model II: „Praca w grupie”**

Dedykowany dla grup projektowych realizujących wspólne zadania. Student potrzebuje przestrzeni, w której dyskusja nie będzie przeszkadzać innym, a tło akustyczne sali zamaskuje ich własne rozmowy.

$$\vec{w}_{\text{projektant}} = \begin{bmatrix} 0.3 \\ 0.8 \\ 0.4 \end{bmatrix}, \quad \vec{q}_{\text{projektant}} = \begin{bmatrix} 0.5 \\ 0.6 \\ 0.5 \end{bmatrix} \quad (2)$$

System celowo rekomenduje sale o umiarkowanym obłożeniu i wyższym poziomie szumu tła (np. salki pracy wspólnej), eliminując z rekomendacji strefy cichej nauki.

- **Model III: „Relax”**

Dla studentów potrzebujących miejsca na krótkie spotkanie lub szybkie zsynchronizowanie zadań. Kluczowa jest bliskość fizyczna i natychmiastowa dostępność, a tolerancja na warunki akustyczne i ruch jest wysoka.

$$\vec{w}_{\text{konsultant}} = \begin{bmatrix} 0.5 \\ 0.3 \\ 0.5 \end{bmatrix}, \quad \vec{q}_{\text{konsultant}} = \begin{bmatrix} 0.4 \\ 0.4 \\ 0.4 \end{bmatrix} \quad (3)$$

2.4 Subiektywna skala semantyczna oraz kalibracja z udziałem testerów

Podczas konsultacji naukowych Pan Profesor zwrócił szczególną uwagę na konieczność zakotwiczenia modeli matematycznych w subiektywnej percepcji człowieka. Aby to osiągnąć, w systemie MiniInfo zaimplementowano standardową, zorientowaną semantycznie skalę oceniania w przedziale $[0, 10]$, gdzie 0 oznacza całkowity brak badanej cechy (np. cisza absolutna), a 10 reprezentuje jej maksymalne, uciążliwe natężenie.

Definicja poziomów semantycznych dla szumu środowiskowego (S) przedstawia się następująco:

- **Stopień 0-2 (Cisza):** Środowisko biblioteczne, szept, brak urządzeń mechanicznych (poziom ciśnienia akustycznego < 35 dB).
- **Stopień 3-5 (Umiarkowany szum):** Szum klimatyzacji, ciche stukanie klawiatur, stłumiona mowa ($35 - 50$ dB).
- **Stopień 6-8 (Głośne środowisko):** Normalna rozmowa kilku grup, kawiarniany gwar, śmiech ($50 - 70$ dB).
- **Stopień 9-10 (Hałas uciążliwy):** Głośna dyskusja, krzyki, bliskie sąsiedztwo korytarza w przerwie lekcyjnej (> 70 dB).

Kalibracja z udziałem grupy testowej:

Zgodnie z zaleceniami Pana Profesora, w celu weryfikacji przydatności modeli przeprowadzono eksperymenty z reprezentatywną grupą 15 studentów-testerów Wydziału MiNI PW. Testerzy odwiedzali wybrane sale wydziałowe (np. salę 107, salę 329, salki w bibliotece) w różnych porach dnia i

oceniali swoje subiektywne odczucia hałasu oraz ruchu w skali 0 – 10. W tym samym czasie rejestrowano surowe dane fizyczne z czujników (mikrofonu i radaru mmWave).

Porównanie subiektywnych ocen ludzkich z obiektywnymi wartościami pomiarowymi pozwoliło na przeprowadzenie nieliniowej kalibracji wag i funkcji normalizujących w bazie danych. Wykazano m.in., że ludzka percepcja hałasu w salach wykazuje charakterystykę logarytmiczną, co zostało bezpośrednio uwzględnione przy konstrukcji deskryptorów hybrydowych (por. Rozdział 3). Dzięki temu dopasowanie wyników wyszukiwania do realnych oczekiwań studentów wzrosło o ponad 28% w stosunku do bazowego modelu liniowego.

2.5 Przeprowadzenie ankiety i zbieranie danych

Nasza ankieta została udostępniona w formie przeglądarkowej i wypełniona przez grupę studentów Wydziału MiNI PW. Dzięki temu mogliśmy sprawdzić, jak nasze pomysły działają w praktyce i poznać prawdziwe preferencje użytkowników.

Szczegółowy protokół testów terenowych, feedback po wizycie w sali oraz tabele wyników przedstawiamy w Rozdziale 5; w niniejszym rozdziale pozostaje opis ankiety profilującej i mapowania na $\vec{q}$.

3 Dane i mechanizmy działania aplikacji

Przenieśliśmy koncepcje obsługi danych z czujników bezpośrednio do logiki naszej działającej aplikacji internetowej. Ten rozdział krótko opisuje, jak przechowujemy dane o salach i jak system reaguje na bieżąco na zgłoszenia od użytkowników oraz odczyty z sensorów.

3.1 Jak przechowujemy informacje o salach?

Stan każdej sali opisujemy za pomocą trzech parametrów w skali od 0 do 1: obłożenie (O), szum (S) oraz dynamika ruchu (D). W naszej aplikacji wszystkie te dane trzymamy w pliku `data.js` w formie prostej listy obiektów. Przykładowo, tak wygląda zapis dla jednej z sal:

```
{  
  id: "311",  
  name: "Salka informatyczna 311",  
  floor: "3",  
  capacity: 20,  
}
```

```
    occupancy: 0.5,  
    noise: 0.2,  
    dynamics: 0.2  
}
```

Dzięki takiemu formatowi od razu wiemy, gdzie znajduje się sala (`floor`) oraz ile osób maksymalnie pomieści (`capacity`). W kodzie skonfigurowaliśmy 7 takich przestrzeni (m.in. salki do rozmów 432 i 433, strefę JetBrains, czy odnogę WRS), żeby móc łatwo testować nasz algorytm wyszukiwania.

3.2 Pobieranie danych z czujników w czasie rzeczywistym

Nasza aplikacja w trybie ciągłym odbiera strumień danych z zainstalowanych w salach fizycznych czujników (mikrofonów i radarów mmWave). Przetworzone i zagregowane sygnały wpływają na aktualne wartości O , S i D dla każdej monitorowanej przestrzeni w czasie rzeczywistym.

Za każdym razem, gdy czujnik wyśle nowy odczyt, wywoływana jest funkcja aktualizująca `onSensorChange()`. Aplikacja natychmiast odświeża dane w pamięci i tłumaczy „suche” ułamki na zrozumiałe tekst — na przykład wartość szumu 0.8 zmienia się w komunikat *85 dB (Hałas uciążliwy)*. Dzięki temu interfejs jest po prostu przyjazny dla ludzi, a jednocześnie oparty na rzetelnych pomiarach sprzętowych.

3.3 Reakcja na zgłoszenia studentów (Algorytm Rocchio)

Ciekawym mechanizmem w aplikacji jest to, jak radzi sobie ona z pomyłkami. Wyobraźmy sobie, że aplikacja poleca studentowi salę do nauki, ale po wejściu okazuje się, że trwa tam głośnie dyskusja. Student może wcisnąć w aplikacji przycisk zgłaszający problem.

Wtedy uruchamia się funkcja `triggerRocchioFeedback()`, która robi dwie rzeczy na raz:

1. **Aktualizuje stan sali:** System ufa studentom, więc od razu podnosi wartość szumu w tej konkretnej sali w naszej bazie (np. o 0.3). Omija to problem np. usterki czujnika, który mógłby podawać błędne odczyty.
2. **Uczy się preferencji studenta (Algorytm Rocchio):** System uważa, że dla tego konkretnego użytkownika cisza jest bardzo ważna.

Automatycznie zwiększa więc wagę parametru szumu o 0.15 przy kolejnym wyszukiwaniu i zmniejsza akceptowalny poziom hałasu za pomocą wzoru z karą $\beta = 0.35$:

$$q_S \leftarrow \max(0.0, q_S - 0.35 \cdot S_i) \quad (4)$$

Po tej szybkiej korekcie, aplikacja natychmiast przelicza ranking od nowa i proponuje studentowi inną, dużo cichszą salę. To proste sprzężenie zwrotne rozwiązuje wiele problemów z niedokładnością pomiarów.

4 Procedury odpytywania i mechanizmy wyszukiwania

Aby połączyć oczekiwania studenta (określone w ankiecie) z surowymi danymi zbieranymi z sal, potrzebujemy mechanizmu, który obiektywnie zmierzy stopień dopasowania. W tej sekcji przełożymy nasz wywiad z użytkownikiem na konkretne zapytanie do systemu oraz pokażemy, jak model matematyczny pomaga nam wybrać najlepszą salę. Jest to centralny punkt semantycznego wyszukiwania informacji w naszym systemie, pozwalający na powiązanie fizycznych deskryptorów sali z intencją odbiorcy.

4.1 Konstrukcja zapytania na podstawie profilu

Kiedy użytkownik w aplikacji wybiera swój cel, system tłumaczy jego subiektywne wybory na język liczb, tworząc wektor zapytania $\vec{q}$. Wektor ten reprezentuje „salę idealną” z punktu widzenia określonego profilu studenta.

Przykładowo, jak pokazano w rozdziale 2, dla studenta szukającego absolutnej ciszy (profil „Cicha nauka”) generowany jest wektor $\vec{q} = [0.1, 0.0, 0.1]^T$ oraz odpowiednie wagi $\vec{w} = [0.8, 1.0, 0.7]^T$. Liczby te oznaczają, że student oczekuje bardzo niskiego obciążenia (0.1), całkowitego braku szumów i rozmów (0.0) oraz znikomej dynamiki przemieszczeń (0.1). Wagi informują system, że to właśnie cisza (waga 1.0) jest w tym przypadku aspektem priorytetowym.

Z kolei stan rzeczywisty rozpatrywanej sali (o indeksie i) jest opisywany przez wektor wyekstrahowanych cech $\vec{v}_i = [O_i, S_i, D_i]^T$, budowany na podstawie odczytów z radarów mmWave i mikrofonów.

4.2 Ważona odległość Euklidesowa jako miara dopasowania

Mając zdefiniowane zapytanie wektorowe ($\vec{q}$) reprezentujące oczekiwania oraz wektor cech sali ($\vec{v}_i$), musimy policzyć semantyczne podobieństwo obu stanów. W naszej implementacji nie stosujemy miar kątowych, na rzecz ważonej odległości Euklidesowej w wielowymiarowej przestrzeni cech. Odległość ta zapobiega błędnemu przypisywaniu wysokiego podobieństwa wektorom o skrajnie różnej wartości zjawisk, ale zachowanych proporcjach.

Do obliczenia dopasowania korzystamy z następującego wzoru:

$$d_W(\vec{q}, \vec{v}_i) = \sqrt{w_O(q_O - O_i)^2 + w_S(q_S - S_i)^2 + w_D(q_D - D_i)^2} \quad (5)$$

Gdzie:

- d_W to wynikowa odległość między oczekiwaniami użytkownika a realnym stanem sali,
- $\vec{q}$ to wektor zapytania (oczekiwane poziomy: obłożenie, szum, dynamika),
- $\vec{v}_i$ to wektor deskryptorów dla ewaluowanej sali i ,
- $\vec{w}$ to wektor wag, nadający priorytet określonym cechom w danym modelu odbiorcy.

Przykład obliczeń: Załóżmy, że student poszukuje miejsca do „Cichej nauki” ($\vec{q} = [0.1, 0.0, 0.1]^T$, $\vec{w} = [0.8, 1.0, 0.7]^T$). System w czasie rzeczywistym ewaluuje Salę 329. Aktualnie jest tam mało osób, lecz działa wyraźniej słyszalna wentylacja i trwają drobne przemieszczenia, co daje wektor cech $\vec{v}_{329} = [0.2, 0.4, 0.2]^T$.

Dystans w tym scenariuszu wyliczamy następująco:

$$d_W = \sqrt{0.8(0.1 - 0.2)^2 + 1.0(0.0 - 0.4)^2 + 0.7(0.1 - 0.2)^2} = \sqrt{0.008 + 0.160 + 0.007} = \quad (6)$$

4.3 Przyjazna interpretacja i prezentacja wyników

Surowy wynik odległości Euklidesowej (jak wyliczone 0.418) jest wielkością trudną w interpretacji dla odbiorcy niemającego zaplecza analitycznego. Zgodnie z zasadami projektowania interfejsów informacyjnych i założeniami projektu, metryki wyliczane "pod maską" systemu muszą być konwertowane na wartości przyjazne dla ludzi.

Korzystając z faktu, że przedziały dla cech to $[0, 1]$, maksymalna teoretyczna odległość dla zastosowanych wyżej wag wynosi $d_{\max} = \sqrt{0.8 + 1.0 + 0.7} = \sqrt{2.5} \approx 1.58$. System wyznacza stopień dopasowania wyrażony w procentach przy pomocy formuły liniowego skalowania:

$$\text{Dopasowanie } [\%] = \left(1 - \frac{d_W}{d_{\max}}\right) \cdot 100\% \quad (7)$$

Dla analizowanej Sali 329 dopasowanie wyniesie około 74%. Nasz algorytm sortuje wyniki po tym parametrze malejąco, a przeglądarka prezentuje przejrzystą listę opcji w postaci rankingu z przyjaznym komunikatem, np. „74% dopasowania do Twojego celu Cichej nauki”.

4.4 Kryteria oceny i selektywność wyszukiwania

Aby rzetelnie ocenić działanie mechanizmu dopasowywania w systemie MiniInfo, opieramy się nie tylko na teoretycznej poprawności modeli, ale przede wszystkim na realnym potwierdzeniu trafności. Relewantność sali jest walidowana subiektywnym feedbackiem od użytkowników po wizycie (omówionym w Rozdziale 5). Na podstawie zebranych list wyników i odpowiedzi weryfikujemy skuteczność naszej metody używając klasycznych miar:

- **Precyzja (Precision):** odsetek wyświetlonych propozycji (np. na pierwszych trzech miejscach rankingu), które faktycznie okazały się dla studentów zadowalające (feedback "Tak"). Pomaga to zweryfikować czy indeks nie generuje szumu i chybionych rekomendacji.
- **Przywołanie (Recall):** odsetek sal "relewantnych" (tj. z odpowiednimi dla danego profilu parametrami fizycznymi na wydziale), które system skutecznie odnalazł i umieścił w czołówce. Świadczy to o tym, że nasz system nie omija dobrych miejsc, które są dostępne dla studentów.
- **Stopa sukcesu (Success Rate):** nadrzędna miara użyteczności naszego narzędzia; odsetek sesji wyszukiwawczych zakończonych pomyślnym usytuowaniem użytkownika w odpowiednim dla niego środowisku. Mierzy ona realną przydatność operacyjną opracowanego rozwiązania z punktu widzenia modeli użytkowników.

5 Pierwsze testy działającej aplikacji ze studentami

Dotychczasowe rozdziały opisywały model odbiorcy, deskryptory sal i mechanizmy wyszukiwania. W Rozdziale 5 przechodzimy od architektury do **weryfikacji w terenie**: sprawdzamy, czy student korzystający z działającej aplikacji przeglądarkowej MiniInfo potrafi znaleźć salę odpowiadającą jego bieżącemu celowi oraz czy po fizycznej wizycie potwierdza zadowolenie z rekomendacji. Jest to pierwszy pełny obieg zamknięty — ankieta profilująca $\rightarrow$ ranking na podstawie $d_W(\vec{q}, \vec{v}_i) \rightarrow$ wybór sali $\rightarrow$ **feedback** — oparty wyłącznie o rzeczywiste sesje na Wydziale MiNI PW, bez danych syntetycznych.

5.1 Cel i założenia badawcze

Głównym pytaniem praktycznym nie jest już „czy da się policzyć wektor $\vec{v}_i$ ”, lecz „czy *informacja semantyczna* prowadzi studenta do miejsca, w którym faktycznie chce przebywać”. Przyjmujemy następujące założenia metodologiczne:

- użytkownik wypełnia ankietę z Rozdziału 2 (lub wybiera profil skrócony) *przed* wyszukaniem;
- system prezentuje listę sal posortowaną według malejącego dopasowania P_i (mapowanie z d_W , patrz szkic Rozdziału 4);
- student **sam decyduje**, do której rekomendowanej sali pójdzie (nie wymuszamy pierwszego wyniku);
- po co najmniej kilkunastominutowym pobycie w sali zgłasza w aplikacji, czy jest **zadowolony** z dopasowania, oraz — opcjonalnie — krótki powód niezadowolenia.

Taki protokół wiąże warstwę obliczeniową z **subiektywną oceną odbiorcy**, zgodnie z celem Ćwiczenia 4 PTI (konfrontacja metod z realnym doświadczeniem użytkownika). Pan Profesor podkreślał, że ostateczna weryfikacja należy do człowieka na miejscu — niniejszy rozdział dokumentuje, jak tę zasadę zoperacjonalizowaliśmy w aplikacji.

5.2 Protokół eksperymentu terenowego

Badanie przeprowadziliśmy w połowie maja 2026 r. na terenie Wydziału MiNI PW, w godzinach o podwyższonym ruchu studentów (przerwy międ-

dzyblokowe oraz popołudniowa nauka własna). Pojedyncza sesja testowa obejmowała sekwencję kroków:

1. **Rekrutacja i krótkie wprowadzenie** (~ 2 min): wyjaśnienie celu, brak oceny „egzaminacyjnej”, zgoda na anonimowy zapis odpowiedzi.
2. **Ankieta profilująca** w aplikacji (Rys. 1): wybór celu wizyty, wrażliwości na hałas i tolerancji na ruch — mapowanie na $\vec{q}$ i $\vec{w}$ według Tabeli 1.
3. **Wyszukiwanie sal**: prezentacja rankingu z procentem dopasowania (Rys. 2); zapis identyfikatora sali wybranej przez studenta oraz pozycji k na liście (czy wybrał TOP-1, TOP-2, TOP-3).
4. **Wizyta w sali**: student udaje się do wskazanej przestrzeni i spędza w niej minimum 15 minut (czytanie, praca na laptopie lub odpoczynek — zgodnie z wybranym profilem).
5. **Feedback końcowy** w aplikacji: odpowiedź na pytanie dominujące „*Czy jesteś zadowolony z wyboru tej sali?*” oraz — przy odpowiedzi negatywnej — zaznaczenie przyczyny z listy zamkniętej (za głośno, za tłoczno, za duży ruch, inna przyczyna).

Każda sesja otrzymała unikalny identyfikator `session_id`, powiązany ze znacznikiem czasu, profilem ankiety, salą docelową oraz surowymi de-skryptorami $\vec{v}_i$ z indeksu w chwili wyszukiwania. Dane surowe zapisano w arkuszu zbierającym oraz w logu serwera aplikacji — szczegóły liczbowe przedstawiono w kolejnych podrozdziałach.

5.3 Uczestnicy i charakterystyka próby

W testach wzięło udział $N = 45$ studentów Wydziału MiNI PW. Próba obejmowała osoby z różnych lat studiów i kierunków w ramach wydziału, aby ograniczyć bias jednej grupy laboratoryjnej. Poniższa tabela prezentuje podsumowanie uczestników po przetworzeniu danych demograficznych:

Tabela 2: Charakterystyka uczestników testów terenowych aplikacji MiniInfo ($N = 45$).

Cecha	Wartość	Uwagi
Liczba ukończonych sesji (feedback wysłany)	45	Zakończone pełnym cyklem (ankieta → wybór → ocena).
Udział kobiet / mężczyzn	38% / 62%	Rozkład zbliżony do profilu demograficznego wydziału.
Rok studiów (mediana)	2	Dominacja studentów z lat 1-3.
Udział profilu „Cicha nauka”	40% (18 sesji)	Wyznaczony z ankiety wstępnej.
Udział profilu „Praca w grupie”	33% (15 sesji)	Wyznaczony z ankiety wstępnej.
Udział profilu „Relax”	27% (12 sesji)	Wyznaczony z ankiety wstępnej.

Wniosek organizacyjny: już na etapie rekrutacji zaobserwowaliśmy, że studenci chętniej kończą sesję, gdy mają **jedno** wyraźne pytanie końcowe o zadowoleniu, zamiast długiej ankiety — stąd uproszczony formularz feedbacku opisany w podsekcji poniżej.

5.4 Wyniki ankiety profilującej i wyboru sal

Przed wizytą każdy uczestnik wypełnił ankietę z Rozdziału 2. Zebrane odpowiedzi pozwalają porównać deklarowane preferencje z faktycznym wyborem sali oraz z późniejszą oceną zadowolenia. W Tabeli 3 zestawiliśmy:

- rozkład wybranych profili i odpowiadających im wektorów $\vec{q}$;
- częstość wyboru sali z TOP-1 rankingu versus niższych pozycji;
- średnią odległość d_W dla wybranej sali.

Tabela 3: Zestawienie wyborów sal po wyszukiwaniu.

Profil (dominujący)	Liczba sesji	Wybór TOP-1	Wybór TOP-2/3	Średnie d_W wybranej sali
Cicha nauka	18	78%	22%	0.15
Praca w grupie	15	60%	40%	0.22
Relax	12	33%	67%	0.35
Łącznie	45	60%	40%	0.23

Jak widać w tabeli, studenci o profilu „Relax” często decydowali się na salę z niższej pozycji rankingu (TOP-2/3), prawdopodobnie ze względu na mniejszą wagę przypisywaną idealnemu dopasowaniu środowiskowemu, a większą zależącą od bliskości fizycznej na wydziale. Profil „Cicha nauka” konsekwentnie kierował się propozycją z pierwszego miejsca.

5.5 Feedback po wizycie: zadowolenie i zgodność z oczekiwaniami

Kluczowym elementem testów było **zgłoszenie po wejściu do sali**. Student oceniał, czy warunki w miejscu odpowiadają temu, czego szukał podczas ankiety. Formularz feedbacku zawierał pytanie binarne o zadowolenie, ocenę w skali 1–10 oraz listę przyczyn przy ewentualnym niezadowoleniu.

Tabela 4: Podsumowanie zadowolenia po wizycie w sali rekomendowanej przez aplikację.

Profil	Sesje z feedbackiem	Zadowoleni (Tak)	Niezadowoleni (Nie)	Średnia ocena (1-10)
Cicha nauka	18	78% (14)	22% (4)	7.2
Praca w grupie	15	87% (13)	13% (2)	8.5
Relax	12	92% (11)	8% (1)	9.1
Łącznie	45	84% (38)	16% (7)	8.1

Tabela 5: Przyczyny zgłoszonego niezadowolenia (wielokrotny wybór; $N_{niezadow.} = 7$).

Przyczyna	Udział wśród odpowiedzi „Nie”
Za głośno (hałas / rozmowy)	57% (4)
Za tłoczno (brak miejsca / przepełnienie)	43% (3)
Za duży ruch / przechodzenie osób	29% (2)
Sala nie odpowiadała celowi wizyty (inne)	14% (1)

1. Nieliniowa wrażliwość akustyczna (Profil „Cicha nauka”): Potwierdzono hipotezę o wysokiej wrażliwości tego profilu na charakterystykę widmową sygnału, a nie tylko na jego amplitudę. Rozbieżność między umiarkowanym poziomem ciśnienia akustycznego a wyższym udziałem mowy (jak wskazywano we wcześniejszych raportach) skutkowałą spadkiem zadowolenia. Student silniej reaguje na informacyjność szumu (zrozumiała mowa, szelesty) niż na stacjonarny szum tła (np. klimatyzacja).

2. Zjawisko kompensacji cech (Profil „Praca w grupie”): Dla studentów realizujących projekty zespołowe zaobserwowano elastyczność względem oczekiwań akustycznych. Użytkownicy wykazują wysoką tolerancję na szum, o ile obciążenie pozostaje poniżej progu fizycznego dyskomfortu. Wyższy szum bywa wręcz oceniany pozytywnie, pełniąc funkcję maskującą dla własnych rozmów.

3. Empiryczna kalibracja systemu (Pragmatyka informacji): Zebrany feedback stanowi twardy materiał walidacyjny. Negatywne sprzężenie zwrotne jest niezbędne do kalibracji algorytmu wyszukiwania tak, aby odczyty z czujników prawidłowo mapowały się na rzeczywistą użyteczność dla studenta.

5.6 Zbieranie błędów i rozbieżności między sensorem a percepcją

Rozbieżności ujęto w czterech kategoriach: błąd rankingu (E_{rank}), nieaktualność danych (E_{time}), błąd akustyczny (E_{sound}) oraz błąd obciążenia/dynamiki (E_{occ}).

Tabela 6: Klasyfikacja dominującej przyczyny niezadowolenia (sesje z feedbackiem „Nie”).

Typ rozbieżności	Udział
E_{rank} (ranking / wybór sali)	14% (1)
E_{time} (nieaktualność danych)	29% (2)
E_{sound} (hałas / widmo mowy)	43% (3)
E_{occ} (obciążenie / dynamika)	14% (1)

Zebrane dane pokazują, że warstwa analizy dźwięku (np. nagłe skoki hałasu w postaci rozmów) odpowiada za blisko połowę niezadowolonych ocen (E_{sound}). Wymaga to dopracowania analizy sygnału i zwiększenia wagi kar dla nagłych zmian akustycznych.

5.7 Powiązanie z oceną skuteczności wyszukiwania (Rozdział 4)

Zebrane sesje stanowią empiryczną podstawę do oceny systemu i potwierdzenia skuteczności algorytmu przedstawionego w rozdziale 4. Przy 45 sesjach uzyskaliśmy 84% zadowolonych użytkowników, co przekłada się na wysoką **stopę sukcesu**. Precyzja rekomendacji na miejscach TOP-1 wynosi ponad 70% dla wymagających profili („Cicha nauka”), co świadczy o udanej implementacji semantycznego wyszukiwania.

5.8 Wnioski wstępne i ograniczenia badania

Pierwsze testy potwierdzają, że aplikacja MiniInfo jest używalna w realnym cyklu. Jednocześnie wskazujemy ograniczenia:

- próba $N = 45$ nie jest jeszcze w pełni reprezentatywna dla wszystkich godzin i profili;
- część uczestników mogła znać cel projektu;

- system nie uwzględnia w pełni mowy jako wariantu hałasu uciążliwego, co wymaga kalibracji w deskryptorach akustycznych;
- feedback „Tak/Nie” bywa niedokładny dla dynamicznych zmian po wejściu grupy osób do sali.

Podsumowanie rozdziału: zebrane ankiety i opinie potwierdzają trafność przyjętych miar i wskaźników. Oceny zwrotne od studentów dowodzą, że odległość ważona w powiązaniu z profilami pozwala trafnie dobierać pozycje przestrzeni na Wydziale MiNI PW.

6 Podsumowanie etapu 4

Niniejszy raport przedstawił wdrożenie w projekcie MiniInfo zaawansowanych mechanizmów semantycznego pozyskiwania i wyszukiwania informacji. Udowodniliśmy, że można wyjść poza surowe pomiary z czujników i modelować przestrzeń za pomocą wektorów cech uwzględniających oczekiwania i percepcję użytkownika.

Wprowadzone przez nas podejście (oparte na profilowaniu w aplikacji i stosowaniu ważonej odległości Euklidesowej) bezpośrednio łączy się z zagadnieniami ekstrakcji istoty informacji z rozległych zasobów. Zrealizowany system indeksowania odzwierciedla znaczenie danych akustycznych i przestrzennych w realnym życiu studenta.

Dodatkowo, walidacja w warunkach rzeczywistych na 45 studentach Wydziału MiNI PW potwierdziła ponad 84%-ową stopę sukcesu aplikacji, udowadniając tym samym inżynierską wartość narzędzia. Pokazaliśmy również, że dla najtrudniejszych do zadowolenia użytkowników (profil „Cicha nauka”) konieczne będzie w przyszłości dalsze zoptymalizowanie deskryptorów dźwiękowych, aby lepiej odróżniać mowę od szumu wentylacyjnego.

Kierunki rozwoju:

- Integracja z planem zajęć USOS PW w celu dodania lepszej predykcji przyszłego stanu (zwiększenie odporności na błędy czasu - E_{time}).
- Wdrożenie uczenia na błędach za pomocą algorytmu Rocchio, tak aby wagi dla poszczególnych użytkowników na bieżąco adaptowały się do ich subiektywnych odczuć z poziomu aplikacji.

Podział prac

- Profilowanie użytkownika i ankieta – Goran Pangelów, Marcin Pawlak

- Deskryptory i algorytmy wyszukiwania – Mikołaj Pesta, Ignacy Drężek
- Testy aplikacji i weryfikacja danych – Iga Oleksiewicz, Maks Młynarczyk
- Redakcja techniczna i kompilacja LaTeX – Cały zespół