

PODSTAWY TEORII INFORMACJI

Laboratorium 5

Raport projektowy MiniInfo

MiniInfo – Raport 5: Weryfikacja skuteczności i podsumowanie projektu

Autorzy

Goran Pangelow

Marcin Pawlak

Mikołaj Pesta

Ignacy Dręzek

Iga Oleksiewicz

Maks Młynarczyk

czerwiec 2026

Spis treści

1	Przypomnienie i kontynuacja Etapu 4	2
1.1	Stan systemu po Etapie 4	2
1.2	Cel Etapu 5	2
1.3	Sprzęt testowy użyty we wczesnych pracach	3
2	Eksperyment weryfikacyjny: skuteczność systemu MiniInfo	3
2.1	Rationale: czym ten eksperyment różni się od Etapu 4 . .	4
2.2	Metodologia	4
2.3	Ground Truth i wskaźniki efektywności	5
2.4	Uczestnicy	6
2.5	Użytkowanie aplikacji w ciągu dwóch tygodni	6
2.6	Wyniki trafności rekomendacji	7
2.7	Analiza niezadowolenia	8
2.8	Wnioski z eksperymentu	9
3	Ankieta zwrotna w aplikacji	10
3.1	Implementacja w kodzie	10
3.2	Przebieg procesu ankiety zwrotnej	12
3.3	Mechanizm przetwarzania feedbacku	13
3.4	Przykładowy scenariusz	13
4	Podsumowanie projektu MiniInfo	13
4.1	Co nam się udało	14
4.2	Co nie działało lub okazało się niepotrzebne	14
4.3	Co było ciekawe i czego się nauczyliśmy	15
4.4	Bilans projektu w punktach	16
4.5	Kierunki dalszego rozwoju	16

1 Przypomnienie i kontynuacja Etapu 4

Niniejszy raport zamyka cykl pięciu etapów projektu MiniInfo. Zanim przejdziemy do weryfikacji i podsumowania, krótko przypominamy stan systemu po Etapie 4, ponieważ stanowi on punkt wyjścia do eksperymentu opisanego w Rozdziale 2.

1.1 Stan systemu po Etapie 4

W Raporcie 4 wdrożyliśmy i przetestowaliśmy pełny cykl semantycznego wyszukiwania informacji w aplikacji MiniInfo:

- **Profilowanie użytkownika** — interaktywna ankieta w trzech krokach (cel wizyty, wrażliwość na hałas, tolerancja na ruch), której odpowiedzi mapowane są na wektor zapytania $\vec{q} = [q_O, q_S, q_D]^T$ oraz wektor wag $\vec{w} = [w_O, w_S, w_D]^T$.
- **Trzy profile użytkownika** — predefiniowane modele odbiorcy: „Cicha nauka”, „Praca w grupie”, „Relax”, odpowiadające typowym scenariuszom na Wydziale MiNI PW.
- **Algorytm rankingowy** — ważona odległość Euklidesowa $d_W(\vec{q}, \vec{v}_i)$ mierząca dopasowanie sali do profilu, z wynikiem prezentowanym jako procent dopasowania.
- **Mechanizm Rocchio** — sprzężenie zwrotne korygujące wektor zapytania po negatywnym feedbacku („za głośno”, „za tłoczno”).
- **Testy z 45 studentami** — stopa sukcesu 84%, średnia ocena 4.1/5 (wówczas skala 1–10, wartość 8.1).

1.2 Cel Etapu 5

Etap 5 realizuje trzy zadania wynikające z wytycznych prowadzącego:

1. **Eksperyment weryfikacyjny** — dwutygodniowe wdrożenie aplikacji u *nowych* użytkowników ($N = 80$), ze zbieraniem logów użytkowania i końcowej ankiety o przydatności w codziennym rytmie studiów; wyniki bez korekt.
2. **Ankieta zwrotna w aplikacji** — opis zaimplementowanego mechanizmu pytania „Czy znalazłeś to, czego szukałeś?” i jego wpływu na system.

3. **Podsumowanie projektu** — bilans całości: co się udało, co nie, jakie popełniliśmy błędy i co byśmy zmienili.

1.3 Sprzęt testowy użyty we wczesnych pracach

Na wczesnym etapie prac deweloperskich, jeszcze przed podłączeniem docelowej infrastruktury czujników mmWave, przeprowadziliśmy testy integracyjne z wykorzystaniem kompaktowego czujnika ruchu PIR (Passive Infrared). Czujnik ten posłużył do walidacji logiki aplikacji — weryfikowaliśmy, czy system poprawnie reaguje na zmiany stanu obecności w pomieszczeniu i czy pipeline danych (odczyt → aktualizacja indeksu → przeliczenie rankingu) działa w czasie rzeczywistym.

Na Rysunku 1 przedstawiono czujnik PIR użyty w fazie prototypowej: widok z przodu z soczewką Fresnela oraz wewnątrz z modułem elektronicznym i zasilaniem baterijnym.



Rysunek 1: Czujnik ruchu PIR użyty w fazie prototypowej: widok z przodu (soczewka Fresnela) oraz wewnątrz (moduł elektroniczny, zasilanie $2 \times \text{AAA}$).

2 Eksperyment weryfikacyjny: skuteczność systemu MiniInfo

Celem eksperymentu było sprawdzenie, czy aplikacja MiniInfo *w codziennym użytkowaniu* pomaga studentom znaleźć odpowiednie miejsce do nauki lub pracy — nie w pojedynczej, kontrolowanej sesji laboratoryjnej, lecz w realnym rytmie tygodnia na wydziale. Wyniki prezentujemy bez korekt.

2.1 Rationale: czym ten eksperyment różni się od Etapu 4

W Raporcie 4 przeprowadziliśmy **jednorazowy test terenowy** ($N = 45$): uczestnik wypełniał ankietę, wybierał salę z rankingu, spędzał w niej ok. 15 minut i od razu oceniał wynik. Procedura była krótka, nadzorowana i dawała wysoką stopę sukcesu (84%), ale mierzyła głównie *pierwsze wrażenie* po wejściu do sali.

Świadomie zaprojektowaliśmy Etap 5 inaczej, aby uzupełnić — a nie powtórzyć — poprzednie badanie:

- **Horyzont czasowy:** 14 dni swobodnego korzystania z aplikacji zamiast jednej sesji.
- **Skala próby:** $N = 80$ nowych użytkowników (żaden nie brał udziału w testach z Raportu 4).
- **Typ danych:** logi użytkowania (ile razy otwarto aplikację, ile rekomendacji zakończono feedbackiem) oraz końcowa ankieta o przydatności w typowym dniu nauki.
- **Perspektywa LAB5:** weryfikacja *pragmatycznej użyteczności* przekazu informacji — czy dane z czujników i ranking realnie wspierają decyzję użytkownika w terenie, a nie tylko w laboratorium.

Taki układ pozwala ocenić nie tylko trafność pojedynczej rekomendacji, lecz także to, *czy studenci wracają do aplikacji* i czy informacja z MiniInfo bywa dla nich przydatna w ciągu dnia.

2.2 Metodologia

Eksperyment trwał w okresie 28 maja–12 czerwca 2026 r. na terenie Wydziału MiNI PW. Procedura obejmowała trzy fazy:

Faza 1 — rekrutacja i onboarding (28 maja, dzień 0).

1. Rekrutacja $N = 80$ studentów Wydziału MiNI PW, którzy *nie* uczestniczyli wcześniej w testach MiniInfo.
2. Krótki instruktaż (~ 3 min): cel aplikacji bez ujawniania algorytmu; instalacja skrótu PWA na telefonie.
3. Jednorazowa ankieta profilująca (cel wizyty, hałas, ruch) — ustalenie profilu bazowego użytkownika.

Faza 2 — dwutygodniowe użytkowanie (29 maja–11 czerwca, dni 1–14). Uczestnicy korzystali z aplikacji według własnych potrzeb, gdy szukali miejsca na wydziale. Po każdej wizycie w sali wybranej na podstawie rankingu aplikacja pytała:

- „Czy znalazłeś/łaś to, czego szukałeś/łaś?” (Tak / Nie),
- ocenę warunków w skali 1–5,
- przy „Nie” — przyczynę (za głośno / za tłoczno / inne).

Logi lokalne rejestrowały liczbę uruchomień, wyświetleń rankingu i sesji z pełnym feedbackiem.

Faza 3 — ankieta końcowa (12 czerwca, dzień 15). Po dwóch tygodniach każdy uczestnik wypełniał ankietę podsumowującą:

- jak często w ciągu typowego dnia na wydziale aplikacja była *realnie przydatna* (skala: nigdy / 1–2 razy / 3–4 razy / 5+ razy),
- ile razy w ciągu 14 dni skorzystał z rekomendacji MiniInfo,
- czy bez aplikacji zwykle wybierałby salę inaczej (pytanie kontrolne dla baseline).

2.3 Ground Truth i wskaźniki efektywności

Zgodnie z wymaganiami LAB5 zdefiniowaliśmy operacyjny wzorzec **Ground Truth (GT)** — co uznajemy za *udaną* rekomendację dla danego profilu:

Tabela 1: Operacyjna definicja sukcesu (GT) w zależności od profilu użytkownika.

Profil	Kryterium sukcesu (odpowieź „Tak” uzasadniona, gdy...)
Cicha nauka	W sali można pracować indywidualnie bez rozmów w bezpośrednim otoczeniu; hałas nie przeszkadza w koncentracji.
Praca w grupie	Jest wolne miejsce dla całej grupy i można prowadzić dyskusję bez zakłócania innych sal.
Relax	Sala spełnia potrzebę krótkiego odpoczynku lub luźnej pracy — bez wymogu absolutnej ciszy.

Główne wskaźniki:

- **Stopa sukcesu** — odsetek sesji z odpowiedzią „Tak” względem wszystkich sesji z pełnym feedbackiem.
- **Średnia ocena 1–5** — średnia arytmetyczna ocen po sesjach (w Etapie 4 stosowaliśmy skalę 1–10; wartości z Raportu 4 można porównać po przeskalowaniu $x_5 = x_{10}/2$).
- **Częstość użytkowania** — mediana uruchomień aplikacji na uczestnika w ciągu 14 dni.
- **Przydatność dzienna** — odsetek osób, które w ankiecie końcowej zadeklarowały przydatność aplikacji co najmniej 1–2 razy dziennie w typowym dniu na wydziale.
- **Baseline subiektywny** — odsetek sesji, w których uczestnik ocenił, że *bez* MiniInfo wybrałby inną salę lub nie wiedziałby, gdzie iść.

2.4 Uczestnicy

W eksperymencie wzięło udział $N = 80$ studentów Wydziału MiNI PW; 76 osób ukończyło pełny 14-dniowy cykl (4 osoby wypadły z powodu choroby lub wyjazdu). Charakterystykę grupy przedstawia Tabela 2.

Tabela 2: Charakterystyka uczestników eksperymentu dwutygodniowego ($N = 80$).


Cecha	Wartość	Uwagi
Ukończone pełne cykle (14 dni)	76	4 osoby przerwały przed końcem.
Kobiety / mężczyźni	44% / 56%	Zbliżone do rozkładu na wydziale.
Rok studiów (mediana)	2	Studenci z lat 1–3.
Profil „Cicha nauka”	42% (34 os.)	Najczęściej wybierany.
Profil „Praca w grupie”	33% (26 os.)	—
Profil „Relax”	25% (20 os.)	—
Mediana uruchomień / 14 dni	9	Od 2 do 22; aktywni użytkownicy.

2.5 Użytkowanie aplikacji w ciągu dwóch tygodni

Łącznie zebrano $S = 712$ sesji z pełnym feedbackiem (ankieta po wizycie w sali). Tabela 3 podsumowuje aktywność grupy.

Tabela 3: Aktywność użytkowników w 14-dniowym okresie testowym.

Metryka	Wartość	Interpretacja
Sesje z pełnym feedbackiem	712	Średnio $\sim 9,4$ sesji na uczestnika.
Aktywni ≥ 3 dni w tygodniu	83% (63/76)	Aplikacja weszła w nawyk tygodniowy.
Przydatna 1–2 razy dziennie	71% (54/76)	Realna użyteczność w codziennym rytmie (ankieta końcowa).
Przydatna 3–4 razy dziennie	38% (29/76)	Rdzeń „power userów” na wydziale.
Baseline: inny wybór bez aplikacji	41% sesji	MiniInfo zmienia decyzję w znaczącej części przypadków.




Rysunek 2: Zaangażowanie użytkowników i deklarowana przydatność dzienna po 14 dniach.

2.6 Wyniki trafności rekomendacji


Poniżej prezentujemy wyniki zadowolenia po wizytach w salach wybranych z rankingu MiniInfo (712 sesji). Wyniki są uczciwe i niepoprawiane.

Tabela 4: Zadowolenie po wizycie w sali rekomendowanej przez aplikację (sesje z 14-dniowego okresu).

Profil	Sesje	Zadowoleni (Tak)	Średnia ocena 1–5
Cicha nauka	304	62% (189)	3.0
Praca w grupie	243	81% (197)	3.6
Relax	165	94% (155)	4.1
Łącznie	712	76% (541)	3.7



Rysunek 3: Odsetek zadowolonych uczestników w podziale na profile (712 sesji).



Rysunek 4: Średnia ocena warunków w sali w podziale na profile (skala 1-5).

2.7 Analiza niezadowolenia

W 171 sesjach uczestnicy zaznaczyli „Nie”. Najczęstsze przyczyny:

Tabela 5: Przyczyny zgłoszonego niezadowolenia ($N_{\text{sesji niezad.}} = 171$).

Przyczyna	Liczba sesji
Za głośno (hałas / rozmowy)	78
Dane w aplikacji nieaktualne (opóźnienie)	49
Sala nie odpowiadała celowi (inne)	44

Typowe scenariusze niepowodzeń (wybrane z ankiet końcowych i komentarzy otwartych):

- **Profil „Cicha nauka” (najczęściej):** Sala była cicha w momencie rekomendacji, ale w trakcie pobytu weszła grupa przygotowująca się do projektu. Przy wielokrotnym użytkowaniu ten scenariusz powtarzał się w godzinach popołudniowych — system nie przewiduje nagłych zmian między odświeżeniami indeksu.
- **Profil „Cicha nauka”:** Odczyty mikrofonu wskazywały niski szum w sali, lecz hałas z korytarza przenikał do pomieszczenia — deskryptor nie rejestruje dźwięku spoza sali.
- **Profil „Praca w grupie”:** Sala okazała się bardziej zajęta niż wskazywał radar mmWave — opóźnienie aktualizacji danych (szczególnie w poniedziałkowe przerwy międzyblokowe).
- **Profil „Relax”:** Pojedyncze przypadki (10 sesji) — zwykle chwilowa zmiana obłożenia sali między zapytaniem a wejściem.

2.8 Wnioski z eksperymentu

Ogólna stopa sukcesu 76% przy 712 sesjach jest **niższa niż jednorazowy test z Etapu 4** (84% przy 45 sesjach), ale uważamy ją za **bardziej wiarygodną miarę pragmatycznej użyteczności**:

1. **Inny protokół, inna informacja.** Etap 4 mierzył pierwsze wrażenie po krótkiej wizycie; Etap 5 — wielokrotne decyzje w ciągu dwóch tygodni, bliżej realnego użytkowania.
2. **Brak efektu testera-eksperta.** Żaden z 80 uczestników nie brał udziału w wcześniejszych testach ani nie znał szczegółów algorytmu.
3. **Wysoka częstość użytkowania.** Mediana 9 uruchomień na osobę i 83% aktywnych co najmniej 3 dni w tygodniu pokazują, że aplikacja nie była jednorazowym gadżetem — studenci *wracali* do niej, gdy szukali miejsca.
4. **Przydatność dzienna.** 71% uczestników deklaruje realną pomoc aplikacji przynajmniej 1–2 razy dziennie w typowym dniu na wydziale.

5. **Ograniczenie sezonowe.** Eksperyment przypadł na koniec maja i początek czerwca — okres zintensyfikowanej nauki przed sesją egzaminacyjną. Wysoka częstość użytkowania (pkt. 3–4) może zatem *równocześnie* wynikać ze zbliżających się egzaminów i większej potrzeby znalezienia miejsca do pracy, a nie wyłącznie z samej użyteczności MiniInfo. To zaburza wnioski dotyczące codziennego nawyku korzystania z aplikacji i należy je traktować ostrożniej niż wyniki trafności rekomendacji.
6. **Profil „Cicha nauka” pozostaje najtrudniejszy** (62% sukcesu). Luźne preferencje profilu „Relax” (94%) są łatwiejsze do spełnienia nawet przy niedokładnych danych — zgodnie z obserwacją z Etapu 4.
7. **Baseline.** W 41% sesji użytkownicy uznaliby, że bez MiniInfo podjęliby inną decyzję — informacja z systemu ma mierzalny wpływ na wybór sali.

Wniosek: algorytm rankingowy *działa poprawnie* i w codziennym użytkowaniu utrzymuje akceptowalną skuteczność, ale — jak w Etapie 4 — jego granicą pozostaje **aktualność danych wejściowych**. System nie gwarantuje, że stan sali w momencie wizyty będzie identyczny ze stanem w momencie zapytania; przy profilu wymagającym ciszy absolutnej nawet niewielkie opóźnienie czujników przekłada się na negatywny feedback.

3 Ankieta zwrotna w aplikacji

Zgodnie z wytycznymi projektu, w aplikacji MiniInfo zaimplementowaliśmy mechanizm zbierania feedbacku po wizycie w sali. Mechanizm ten był wykorzystywany zarówno w jednorazowych testach z Raportu 4, jak i w dwutygodniowym eksperymencie z Rozdziału 2 (każda z 712 sesji kończyła się pytaniem o zadowolenie). Celem jest ocena jakości rekomendacji oraz adaptacja systemu do preferencji użytkownika.

3.1 Implementacja w kodzie

Mechanizm feedbacku jest zaimplementowany bezpośrednio w pliku `app.js` jako funkcja `triggerRocchioFeedback()`. Użytkownik po wizycie w sali może zgłosić problem, klikając odpowiedni przycisk w interfejsie aplikacji.

Interfejs oferuje dwie ścieżki:


- „Tak” — sesja zamknięta pozytywnie, dane zapisane bez zmian.

- „Nie” — użytkownik wskazuje przyczynę (za głośno / za tłoczno). System uruchamia procedurę korekty.

Na Rysunkach 5 i 6 przedstawiono interfejs aplikacji: ekran ankiety profilującej oraz ekran wyników wyszukiwania z procentem dopasowania.




Rysunek 5: Ekran ankiety profilującej w aplikacji MiniInfo.



Rysunek 6: Ranking sal z procentem dopasowania do profilu.

3.2 Przebieg procesu ankiety zwrotnej

Diagram 7 przedstawia pełny przebieg procesu od momentu zgłoszenia problemu do aktualizacji wyników wyszukiwania.



Rysunek 7: Przebieg procesu ankiety zwrotnej — od zgłoszenia do aktualizacji rankingów.

3.3 Mechanizm przetwarzania feedbacku

Negatywny feedback przetwarza się dwuetapowo:

1. Brama mediany (zabezpieczenie przed nadużyciami). Pojedyncze zgłoszenie nie zmienia danych sali. Dopiero gdy co najmniej 3 niezależne osoby zgłoszą problem dla tej samej sali, system oblicza medianę z ich zgłoszeń i uruchamia korektę. Mediana (zamiast średniej) chroni przed fałszywymi skargami i jednorazowymi anomaliami.

2. Korekta wektora zapytania (algorytm Rocchio). Jeśli użytkownik zgłosi, że w sali było za głośno, system automatycznie:

- zwiększa wagę parametru szumu: $w_S \leftarrow \min(1.0, w_S + 0.15)$,
- przesuwa wartość docelową szumu w dół:

$$q_S \leftarrow \max(0.0, q_S - 0.35 \cdot S_i) \quad (1)$$

gdzie S_i to aktualny poziom szumu w zgłoszonej sali, a $\beta = 0.35$ to kara za błąd.

Po korekcie system natychmiast przelicza ranking i proponuje alternatywną, cichszą salę. Dzięki temu aplikacja *uczy się* na błędach i z czasem lepiej dopasowuje się do konkretnego użytkownika.

3.4 Przykładowy scenariusz

Student szuka ciszy przed egzaminem. Aplikacja poleca salę 432 z dopasowaniem 89%. Po wejściu okazuje się, że w sali odbywa się spotkanie grupowe. Student zgłasza: „Nie” $\rightarrow$ „Za głośno”. Reakcja systemu:

1. Zgłoszenie zapisane do kolejki dla sali 432.
2. Jeśli to trzecie zgłoszenie w krótkim czasie — system aktualizuje poziom szumu sali na podstawie mediany.
3. Waga ciszy dla tego użytkownika wzrasta ($w_S : 0.85 \rightarrow 1.0$), a wartość docelowa szumu spada ($q_S : 0.15 \rightarrow 0.0$ po korekcie Rocchio).
4. Kolejne wyszukiwanie pominie salę 432 i zaproponuje cichszą alternatywę (np. pokój 537).

4 Podsumowanie projektu MiniInfo

To ostatni raport z projektu. Podsumowujemy uczciwie: co naprawdę zrobiliśmy, co działało, co nie, i czego się nauczyliśmy.

4.1 Co nam się udało

- **Działająca aplikacja webowa.** Zbudowaliśmy od zera aplikację mobilną (HTML/CSS/JS) działającą w przeglądarce na telefonie. Użytkownik może wypełnić ankietę, zobaczyć ranking sal i przejść do wybranej sali — bez instalacji czegokolwiek.
- **Algorytm rankingowy.** Wazona odległość Euklidesowa w przestrzeni $[0, 1]^3$ daje sensowne wyniki. System mierzy dopasowanie sali do profilu matematycznie, a nie przez proste filtrowanie.
- **Trzy profile użytkownika.** Ankieta 3-krokowa zamienia subiektywne preferencje na konkretne wektory zapytań $\vec{q}$ i wagi $\vec{w}$. Profile „Cicha nauka”, „Praca w grupie” i „Relax” pokrywają najczęstsze scenariusze na wydziale.
- **Sprzężenie zwrotne (Rocchio).** Mechanizm korekty po negatywnym feedbacku jest zaimplementowany i działa — system adaptuje się do użytkownika.
- **Dynamiczna aktualizacja danych.** System w tle cyklicznie pobiera nowe odczyty z czujników i odświeża indeks sal. Drobne zmiany (wejście/wyjście pojedynczych osób) rejestrowane są co minutę, większe przesunięcia — w dłuższych interwałach.
- **Zabezpieczenie — brama mediany.** Feedback od pojedynczego użytkownika nie zmienia danych sali. Dopiero 3 niezależne zgłoszenia uruchamiają korektę, a system bierze medianę — nie średnią.
- **Dwa uzupełniające się eksperymenty z prawdziwymi użytkownikami.** Testowaliśmy aplikację łącznie na 125 osobach (45 w jednorazowym teście z Etapu 4, 80 w dwutygodniowym wdrożeniu z Etapu 5) oraz zebraliśmy 712 sesji z feedbackiem. Wyniki nie są idealne, ale są prawdziwe i pozwalają ocenić mocne i słabe strony systemu.
- **Kompletna dokumentacja.** Pięć raportów opisuje pełną ścieżkę: od koncepcji i analizy sygnałów, przez ekstrakcję informacji i semantyczne wyszukiwanie, po weryfikację i podsumowanie.

4.2 Co nie działało lub okazało się niepotrzebne

- **Pierwotna koncepcja MiniMaps.** W Raporcie 1 założyliśmy aplikację nawigacyjną na wzór Google Maps — mapę wydziału z planami ewakuacyjnymi, wyszukiwaniem sal dydaktycznych i analizą węzłów

nawigacyjnych (m.in. dylemat „schody czy winda”). Po ocenie prowadzącego uznaliśmy ten kierunek za *fiasko*: skupienie na geometrii budynku pominęło kluczowe dla PTI aspekty przepływu danych, wiarygodności pomiaru i redukcji nadmiarowości, a problem odnajdywania sal okazał się barierą chwilową, zbyt wąską podstawą złożonego systemu informacyjnego. W Raporcie 2 całkowicie zmieniliśmy temat na dynamiczne monitorowanie zajętości sal (MiniInfo). Lekcja: zbyt wzniosłe, trudne do domknięcia w ramach laboratoriów cele na starcie projektu kosztowały nas miesiąc pracy i wymusiły restart od zera.

- **Brak integracji z planem zajęć USOS.** Planowaliśmy, że system będzie przewidywał stan sali na podstawie harmonogramu (np. że za 20 minut skończy się wykład i sala zostanie opanowana przez grupę). Nie wdrożyliśmy tego — to największa funkcjonalna luka projektu.
- **Podobieństwo kosinusowe.** Rozważaliśmy je jako alternatywną metrykę, ale odrzuciliśmy: wektory w $[0, 1]^3$ mogą mieć kąt zerowy mimo semantycznie przeciwnych wartości (np. $[0.1, 0.1, 0.1]^T$ vs. $[0.9, 0.9, 0.9]^T$). Ważona odległość Euklidesowa okazała się lepsza.
- **Opóźnienie aktualizacji danych.** Stan sali może się zmienić szybciej, niż czujniki zdążą odświeżyć indeks. W eksperymencie Etapu 5 49 z 171 negatywnych sesji (29%) wskazało nieaktualne dane jako przyczynę.
- **Panel diagnostyczny (suwaki).** Początkowo aplikacja miała panel do manualnego zmieniania wartości sal suwakami. Było to narzędzie developerskie, które niepotrzebnie komplikowało interfejs. Zastąpiliśmy go mechanizmem zgłaszania błędów.
- **Ograniczona liczba czujników.** System monitoruje tylko 7 sal, a czujniki nie uwzględniają wszystkich czynników środowiskowych (np. bliskość głośnego korytarza, przenikanie dźwięku przez ściany). To ograniczenie wymaga dalszej kalibracji.

4.3 Co było ciekawe i czego się nauczyliśmy

- **Subiektywność jest mierzalna.** Na początku projektu nie było oczywiste, że da się zamienić preferencje typu „chcę ciszy” na liczby i dobrze posortować wyniki. Okazało się, że prosta ankieta + ważona metryka wystarczą do sensownych rekomendacji.

- **Profil „Relax” jest łatwy, „Cicha nauka” — trudny.** Wynikło to empirycznie z obu eksperymentów. Algorytm dobrze radzi sobie z luźnymi preferencjami; gorzej z rygorystycznymi wymaganiami absolutnej ciszy.
- **Mediana jest lepszą barierą niż próg.** Decyzja o użyciu mediany zamiast prostego licznika zgłoszeń chroni przed fałszywymi alarmami i celowym manipulowaniem danymi.
- **Prosta aplikacja mobilna może działać bez backendu.** Wszystko, co zbudowaliśmy, działa po stronie klienta — bez serwera, bez bazy danych w chmurze. To znacząco upraszcza deployment na wydziale.
- **Jakość danych $>$ jakość algorytmu.** Nasz algorytm rankingowy działa poprawnie, ale jego skuteczność jest ograniczona przez jakość danych wejściowych. Nawet najlepszy wzór nie pomoże, jeśli dane nie odzwierciedlają rzeczywistości.

4.4 Bilans projektu w punktach

Tabela 6: Bilans projektu MiniInfo: plusy i minusy.

Plusy (+)	Minusy (–)
Działająca aplikacja webowa (HTML/CSS/JS)	Ograniczona liczba monitorowanych sal
Algorytm ważonej odległości Euklidesowej	Brak integracji z USOS
3 profile użytkownika z ankietą	Opóźnienie aktualizacji danych
Mechanizm Rocchio (feedback adaptacyjny)	Badanie ograniczone do Wydziału MiNI PW
Brama mediany (ochrona przed nadużyciami)	Brak analizy widma dźwięku (mowa vs. szum)
Dynamiczna aktualizacja z czujników	Aplikacja działa tylko lokalnie
2 eksperymenty (125 osób, 712 sesji)	Tylko 7 sal w indeksie

4.5 Kierunki dalszego rozwoju

Gdyby projekt był kontynuowany, priorytetem byłyby:

1. **Integracja z planem zajęć USOS** — system mógłby przewidywać stan sali na najbliższe godziny na podstawie harmonogramu.

2. **Większa sieć czujników** — więcej radarów mmWave i mikrofonów zainstalowanych w kolejnych salach na wydziale.
3. **Personalizacja historyczna** — system pamięta historię wyborów użytkownika i z czasem lepiej dopasowuje rekomendacje bez konieczności powtarzania ankiety.
4. **Rozszerzenie indeksu sal** — aktualnie 7 sal; na wydziale jest ich znacznie więcej.
5. **Analiza widma dźwięku** — rozróżnienie mowy (uciążliwa) od szumu tła (akceptowalny), co znacząco poprawiłoby trafność dla profilu „Ci-cha nauka”.

Podział prac

- Eksperyment weryfikacyjny i analiza wyników – Iga Oleksiewicz, Maks Młynarczyk
- Mechanizm ankiety w aplikacji i feedback – Marcin Pawlak, Ignacy Drężek
- Podsumowanie projektu i wnioski – Goran Pangelow, Mikołaj Pesta, Marcin Pawlak
- Redakcja techniczna i kompilacja L^AT_EX – Mikołaj Pesta, Goran Pangelow